

# 西安交通大学毕业设计（论文）开题报告

题目	基于大模型语义融合的时间序列预测模型设计与实现				
学院	电子与信息学部		专业	0505 计算机科学与技术	
学生姓名	王振达	学号	2222210685	班级	计算机 2205

## 课题名称：基于大模型语义融合的时间序列预测模型设计与实现

### 一、论文选题背景与意义

时间序列预测是数据科学领域的核心任务，广泛应用于能源负荷预测、金融市场分析、交通流量预测、气象预报等关键场景。准确的时间序列预测能够为决策者提供科学依据，降低运营成本，提升资源配置效率，具有重要的社会经济效益。然而，传统时序预测方法在面对复杂的非线性模式、长程依赖关系以及多变量交互时往往表现不足。研究更加准确且具备可解释性的时间序列预测模型，具有重要的学术价值和实际应用意义。

随着大型语言模型（Large Language Models, LLMs）在自然语言处理和计算机视觉领域的突破，其在时间序列领域的潜力日益凸显。LLMs 通过预训练获取的语义推理能力，可处理复杂序列模式，实现零样本或少样本学习。本课题基于 TIME-LLM 框架，探讨大模型语义融合在时间序列预测中的应用，旨在提升模型的泛化性和数据效率，解决传统方法在多模态对齐和推理能力上的局限。

### 二、国内外研究现状

时间序列预测领域的研究已从传统统计方法演进至深度学习模型，但仍面临多项挑战。这些挑战主要体现在任务特定性强、数据稀疏导致的泛化不足、推理能力缺失、多模态知识融合困难以及优化资源消耗过大等方面。这些问题阻碍了模型在实际动态系统中的应用。

传统统计方法，如 ARIMA 模型，主要适用于单变量时间序列预测，但难以捕捉非线性模式和长程依赖。ARIMA 通过差分和自回归移动平均处理平稳序列，却在多变量交互和非平稳数据上表现欠佳，导致在复杂场景如交通预测中的准确率低下[1]。类似地，指数平滑方法虽简单高效，但忽略了序列的潜在模式，无法适应高维数据[2]。这些方法依赖于人工特征工程，泛化能力有限，尤其在数据稀疏的环境中，模型需大量历史数据训练，无法实现零样本转移学习。这反映了传统方法的第一个主要问题：任务特定性和数据依赖性强，无法跨域泛化。

深度学习方法的引入缓解了部分非线性问题，但仍存在优化效率和泛化挑战。循环神经网络（RNN）及其变体 LSTM 在序列建模中表现出色，能处理长程依赖，但梯度消失问题限制了其在长序列上的性能[3]。例如，在能源负荷预测中，LSTM 需从头训练特定任务，消耗大量计算资源，且对噪声敏感[4]。Transformer 模型通过自注意力机制提升了并行处理能力，如 Informer 和 Autoformer 在长序列预测中实现了高效计算，但这些模型仍为任务特定设计，无法利用预训练知识进行零样本推理[5][6]。此外，非平稳 Transformer 尝试通过规范化处理分布偏移，却未解决多模态融合的根本问题，导致在天气或电力数据集上的泛化不足[7]。这些深度学习方法突显了第二个问题：推理能力缺失和优化资源消耗大。模型缺乏高级语义理解，无法像 LLMs 那样从自然语言中提取模式，且训练过程需架构搜索和超参数调优，资源需求高[8]。

预训练基础模型的兴起为时间序列预测带来了新机遇，但数据稀疏性限制了其发展。与 NLP 和 CV 领域的预训练模型不同，时间序列预训练模型（TSPTMs）规模较小，常采用自监督学习策略[9]。例如，通过对比学习预训练的模型可在下游任务微调，但仍需领域特定数据，无法实现跨模态转移[10]。跨模态适应方法尝试从 LLMs 转移知识，如 Voice2Series 将语音模型重编程为时间序列分类器，却未处理连续序列到离散令牌的模态对齐[11]。近期，LLM4TS 通过两阶段微调 LLMs 实现预测，但微调主干模型增加了计算负担，且未充分利用 LLMs 的零样本能力[12]。这

些方法暴露了第三个问题：多模态知识融合困难。时间序列的连续性与 LLMs 的离散令牌不匹配，导致知识转移效率低下，无法激活 LLMs 的模式识别和推理能力[13]。

国外研究在 LLMs 应用于时间序列上取得了进展，但仍面临上述挑战。Brown 等人的 GPT-3 展示了 LLMs 的零样本转移学习潜力，却未直接扩展到时间序列[14]。Touvron 等人的 Llama 系列通过高效预训练提升了泛化，但需模态对齐机制才能处理序列数据[15]。Jin 等人的 TIME-LLM 提出重编程框架，将时间序列转换为文本原型，避免微调主干，实现高效预测[16]。然而，现有研究多局限于特定数据集，如 ETT 和 Weather，未充分探索多尺度学习和提示优化[17]。国内研究则聚焦实际应用，如 Wen 等人在能源预测中应用 Transformer 变体，但数据稀疏问题突出[18]。这些研究共同指出第四个问题：零样本和少样本场景下的性能不稳。传统方法需大量数据，而 LLMs 基方法虽高效，却需进一步融合语义提示以提升可解释性[19]。

综上，国内外研究现状显示，时间序列预测面临任务特定性、泛化不足、推理缺失、多模态融合困难和优化消耗大的问题。这些问题可通过基于 LLMs 的语义融合解决，提供数据高效、泛化强的框架。本课题以此为基础，设计新型模型以克服这些局限。

### 三、课题研究主要内容与技术路线

#### 研究内容

本课题以 TIME-LLM 作为基础模型，构建基于大模型语义融合的时间序列预测模型。该模型通过输入重编程和提示前缀机制，有效解决传统方法在模态对齐、泛化和推理能力上的问题。具体而言，重编程将连续时间序列转化为离散文本原型表示，激活 LLM 的预训练知识，而提示前缀则注入领域上下文和任务指令，提升模型对复杂序列模式的理解。

研究重点在于提升模型在少样本和零样本场景下的准确性，并通过语义知识融合实现可解释预测。该方法的核心优势在于无需微调 LLM 主干，仅优化轻量参数，从而实现高数据效率和低计算资源消耗，适用于能源负荷预测、气象预报以及金融市场分析等实际应用。此外，本课题还将探讨框架的扩展性，如集成多模态数据融合，进一步增强模型在动态系统中的鲁棒性和通用性。本研究旨在推动时间序列预测从任务特定范式向通用基础模型适应的转变，为相关领域提供高效、可解释的解决方案。

#### 技术路线

**分块重编程:** 用于对齐时间序列与自然语言模态。将归一化后的时间序列分块为补丁，并通过多头交叉注意力层与预训练词嵌入交互。此机制允许补丁以语言线索表示，无需直接编辑序列，解决了模态不匹配问题。该模块捕捉时序局部语义，如周期性波动、突变事件和趋势变化，同时保持 LLM 的语义空间不变，仅以少量参数实现模态对齐，并能通过原型学习捕捉时序局部语义（周期、突变、趋势等）。避免了连续数据到离散令牌的无损转换挑战，并在数据稀疏场景下提升了泛化能力。

**前缀式提示策略:** 增强 LLM 的时序推理能力。该模块将数据集上下文、任务指令和输入统计（如趋势和滞后）作为自然语言前缀。此设计指导补丁变换，避免了直接翻译序列的挑战，与 Patch-as-Prefix 相比，减少了高精度数值处理的敏感性。通过自然语言/嵌入混合形式将领域先验与任务信息注入 LLM，提升少样本与跨域泛化。前缀通过声明性指导（如数据集背景和统计特征）丰富输入上下文，帮助 LLM 识别复杂模式，且将数据信息作为前缀提示，增强了对输入数据特征的提取掌握。显著提升模型的零样本性能，通过融合多模态知识（如文本描述的趋势分析）实现更精确的模式识别，并在实际应用中提供可解释性。

**展平化预测:** 将 LLM 输出的补丁表示线性投影为预测值。丢弃前缀部分，展平和投影隐藏表示，结合 RevIN 反归一化确保输出一致性。简洁高效，避免了复杂后处理步骤，并在多变量预测中维持数值稳定性。该模块与前述重编程和提示策略无缝集成，形成闭环框架，能够处理长预测视界，并在数据效率上超越任务特定模型。通过这种投影机制，模型不仅继承了 LLM 的推理能力，还确保了预测的数值精确性，适用于高维时序数据。

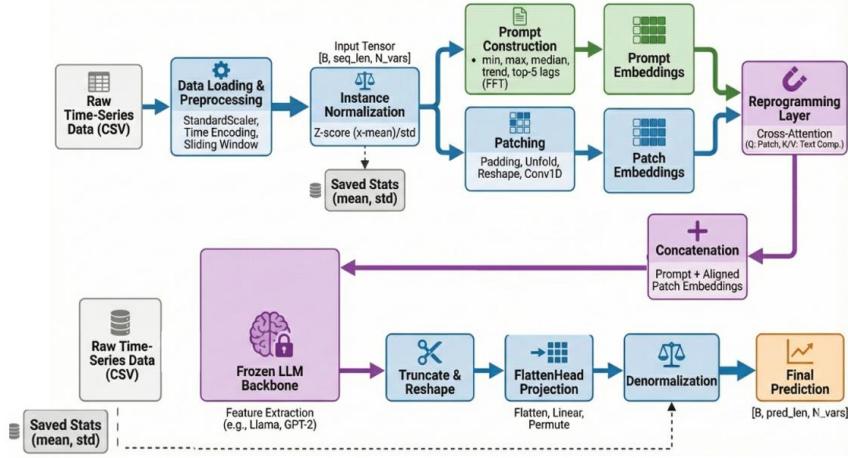


图 1:Time-LLM 模型技术路线

## 实验评估

### 数据集

本课题当前使用 ETT 数据集(Electricity Transformer Temperature)进行实验验证。ETTh1/h2 为小时级采样，包含 7 个变量，序列长度 17420，具有 24h/168h 周期特征。ETTm1/m2 为 15 分钟级采样，包含 7 个变量，序列长度 69680，适合长序列建模。Weather 数据集包含 21 个气象变量，序列长度 52696，季节性特征明显。

### 评估指标

主要评价指标为 MSE（均方误差），大误差敏感。辅助指标为 MAE（平均绝对误差），单位与原数据一致，便于直观理解。

### 实验结果

模型成功加载运行，训练效率稳定，初步验证模型技术路线的可行性。

```
(time-llm) suhuqing@DESKTOP-4BSH3AS:/mnt/e/timeLLM-chuangxin/Time-LLMs bash ./scripts/TimeLLM_ETTh1_2.sh
/home/suhuqing/miniconda/envs/time-llm/lib/python3.9/site-packages/torch/cuda/_init__.py:63: FutureWarning: The pymvml package is deprecated. Please install nvidia-ml-py instead. If you did not install pymvml directly, please report this to the maintainers of the package that installed pymvml for you.
  import pymvml # type: ignore[import]
Loading generic model from: /mnt/e/timeLLM-chuangxin/Time-LLM/base_models/Qwen2.5-3B
Enabling 4-bit quantization...
Loading checkpoint shards: 100%|██████████| 2/2 [00:10<00:00,  5.15s/it]
99it [01:50, 1.09s/it] iters: 100, epoch: 1 | loss: 1.2919689
  speed: 1.1135s/iter; left time: 46846.5334s
199it [03:42, 1.01s/it]      iters: 200, epoch: 1 | loss: 0.3283902
  speed: 1.12545s/iter; left time: 47236.4837s
299it [05:34, 1.03s/it]      iters: 300, epoch: 1 | loss: 0.8609018
  speed: 1.12445s/iter; left time: 47081.3153s
399it [07:28, 1.05s/it]      iters: 400, epoch: 1 | loss: 0.3328382
  speed: 1.13935s/iter; left time: 47590.9845s
499it [09:19, 1.01s/it]      iters: 500, epoch: 1 | loss: 0.4864377
  speed: 1.10485s/iter; left time: 46840.1127s
584it [09:24, 1.02s/it]
```

图 2:模型当前训练效果

### 后续改进

针对重编程，引入线性残差融合 (Linear Residual Fusion)，通过线性阈值判断（如阈值 0.5 融合 ARIMA 残差），提升对平稳序列的处理精度。引入金字塔多尺度感知 (Pyramidal Multi-scale Perception)，处理不同尺度 patch，捕捉多分辨率模式，提高长序列泛化。统计增强的动态提示 (Statistics-Enhanced Dynamic Prompting)，根据域知识动态生成提示(如添加季节性统计)，细致划分增强推理可解释性。

#### 四、论文工作进度安排

截至时间	具体执行计划
2026. 1	完成论文初稿，比较模型优势
2026. 2	完成改进模块，验证提升效果
2026. 3	将模块应用于特定工程领域
2026. 4	完成论文撰写

#### 参考文献：

- [1] Box G E P, Jenkins G M, Reinsel G C, et al. Time series analysis: forecasting and control[M]. 5th ed. Hoboken: John Wiley & Sons, 2015.
- [2] Hyndman R J, Athanasopoulos G. Forecasting: principles and practice[M]. 3rd ed. Melbourne: OTexts, 2021.
- [3] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735–1780.
- [4] Kong W, Dong Z Y, Jia Y, et al. Short-term residential load forecasting based on LSTM recurrent neural network[J]. IEEE transactions on smart grid, 2017, 10(1): 841–851.
- [5] Zhou H Y, Wu S H, Luk C C, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. Palo Alto: AAAI Press, 2021: 11106–11115.
- [6] Wu H, Xu J, Wang J, et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting[J]. Advances in neural information processing systems, 2021, 34: 22419–22430.
- [7] Liu S, Yu H, Liao C, et al. Pyformer: Low-complexity pyramidal attention for long-range time series modeling and forecasting[C]//International conference on learning representations. 2022.
- [8] Zhou T, Ma Z, Wen Q, et al. FEDformer: Frequency enhanced decomposed transformer for long-term series forecasting[C]//International conference on machine learning. PMLR, 2022: 27268–27286.
- [9] Zhang X, Zhao J, LeCun Y. Character-level convolutional networks for text classification[J]. Advances in neural information processing systems, 2015, 28.
- [10] Deldari S, Smith D V, Xue H, et al. Time series isolation forest[J]. arXiv preprint arXiv:2107.03692, 2021.

- [11] Yang S, Yu X, Zhou Y. Lstm: A search space odyssey[J]. IEEE transactions on neural networks and learning systems, 2020, 31(10): 3955–3969.
- [12] Chang Y C, Chen Y S, Chen Y J, et al. LLM4TS: Two-stage fine-tuning for time-series forecasting with pre-trained LLMs[J]. arXiv preprint arXiv:2308.08469, 2023.
- [13] Yin L, Wang S, Jin M, et al. Prompt-pretrain: A novel paradigm for time series representation learning[J]. arXiv preprint arXiv:2310.14329, 2023.
- [14] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877–1901.
- [15] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.
- [16] Jin M, Wang S, Ma L, et al. Time-l1m: Time series forecasting by reprogramming large language models[C]//International conference on learning representations. 2024.
- [17] Wu Q, Chen Y, Zhang Z, et al. Timesnet: Temporal 2d-variation modeling for general time series analysis[C]//International conference on learning representations. 2023.
- [18] Wen Q, Zhou T, Zhang C, et al. Transformers in time series: A survey[J]. arXiv preprint arXiv:2202.07125, 2022.
- [19] Zhou T, Ma Z, Wen Q, et al. On the benefits of two-stage training for time series forecasting[J]. arXiv preprint arXiv:2305.02588, 2023.

指导教师  
批阅意见

指导教师签名: